

# Resumen de Matrices, Funciones y Optimización

Bernardita Vial

Segundo semestre de 2015

## 1 Matrices y concavidad de funciones

### 1.1 Menores principales y matriz negativa definida

- $\Delta_r$ , **menores principales** de orden  $r$  de matriz  $A_{n \times n}$ :
  - $\Delta_r$  son los determinantes de las sub-matrices de  $A$  obtenidas al borrar  $n - r$  filas y columnas de  $A$  de igual índice (submatrices de orden  $r \times r$  porque se borran todas menos  $r$ ).
  - ejemplo, si  $n = 3$  y  $r = 1$ , un menor principal resulta de borrar las primeras dos filas y columnas; otro de borrar las dos últimas filas y columnas, y otro de borrar las primeras y terceras.
- $D_r$ , **menores principales líderes** de orden  $r$  de  $A_{n \times n}$ :
  - $D_r$  son los determinantes de las sub-matrices obtenidas al borrar **las últimas**  $n - r$  filas y columnas de  $A$  de igual índice (submatrices de orden  $r \times r$  porque se borran todas menos las  $r$  primeras filas y columnas).
  - en ejemplo, el menor principal líder es el que resulta de borrar las dos últimas filas y columnas.
- La matriz  $A$  es **negativa semidefinida** si  $(-1)^r \Delta_r \geq 0$  y **negativa definida** si  $(-1)^r D_r > 0$
- La matriz  $A$  es **positiva semidefinida** si  $\Delta_r(\mathbf{x}) \geq 0$ , y **positiva definida** si  $D_r(\mathbf{x}) > 0$

### 1.2 Funciones

- Una función es una relación de  $X$  a  $Y$  en que cada elemento de  $X$  se relaciona con un único elemento de  $Y$ .
  - Si  $f : X \rightarrow Y$ , escribimos  $y = f(x)$ .
  - Veremos funciones reales  $f : S \rightarrow \mathbb{R}$ .
- $f$  se dice **cóncava** si:
$$f(\lambda x + (1 - \lambda)x') \geq \lambda f(x) + (1 - \lambda)f(x')$$
para todo  $x, x' \in S$  y  $\lambda \in [0, 1]$  (estricta si  $>$  estricto para todo  $\lambda \in (0, 1)$  con  $x \neq x'$ ).
- $f$  se dice **convexa** si  $-f$  es cóncava
- Si  $f$  es (dos veces) diferenciable, concavidad se puede expresar en términos de la matriz de segundas derivadas de  $f$  (Hesiano, que denotaremos por  $H_f(\mathbf{x})$ ):
  - Una función  $f$  es cóncava ssi  $H_f(\mathbf{x})$  es negativa semidefinida en todo su dominio (cóncava estricta si  $H_f(\mathbf{x})$  negativa definida).

- Una función  $f$  es convexa ssi  $H_f(\mathbf{x})$  es positiva semidefinida en todo su dominio (cóncava estricta si  $H_f(\mathbf{x})$  positiva definida).

- $f$  se dice **cuasi-cóncava** si:

$$f(\lambda x + (1 - \lambda)x') \geq \min\{f(x), f(x')\}$$

para todo  $x, x' \in S$  y  $\lambda \in [0, 1]$  (estricta si  $>$  estricto para todo  $\lambda \in (0, 1)$  con  $x \neq x'$ ).

- Similarmente,  $f$  se dice **cuasi-convexa** si:

$$f(\lambda x + (1 - \lambda)x') \leq \max\{f(x), f(x')\}$$

para todo  $x, x' \in S$  y  $\lambda \in [0, 1]$

- Si  $f$  es (dos veces) diferenciable, cuasi-concavidad se puede expresar en términos de la matriz horlada de segundas derivadas (que denotaremos por  $\overline{H}_f(\mathbf{x})$ ):

$$\overline{H}_f(\mathbf{x}) = \begin{bmatrix} 0 & f_1(\mathbf{x}) & \dots & f_n(\mathbf{x}) \\ f_1(\mathbf{x}) & f_{11}(\mathbf{x}) & \dots & f_{1n}(\mathbf{x}) \\ \vdots & \vdots & \ddots & \vdots \\ f_n(\mathbf{x}) & f_{n1}(\mathbf{x}) & \dots & f_{nn}(\mathbf{x}) \end{bmatrix}$$

- Condición necesaria para  $f$  cuasicóncava:  $(-1)^r \overline{D}_r(\mathbf{x}) \geq 0$ , donde  $\overline{D}_r$  es el menor principal líder de orden  $r$  de la matriz  $\overline{H}_f(\mathbf{x})$
- Condición suficiente para  $f$  cuasicóncava:  $\overline{H}_f(\mathbf{x})$  negativa definida, i.e.,  $(-1)^r \overline{D}_r(\mathbf{x}) > 0$

## 2 Optimización

Revisaremos condiciones necesarias y suficientes para un óptimo al analizar el problema de maximización de una función  $f: \mathbb{R}^n \rightarrow \mathbb{R}$ , posiblemente sujeta a restricciones expresadas a través de funciones  $g_j$ . Supondremos que  $f$  es doblemente diferenciable y que cada  $g_j$  es diferenciable.

Si  $\mathbf{x}^*$  resuelve el problema de maximización de  $f$  dentro de un conjunto  $A$ , decimos que  $\mathbf{x}^* = \arg \max_{\mathbf{x} \in A} f(\mathbf{x})$

El valor de la función evaluada en el óptimo es  $f(\mathbf{x}^*)$ .

### 2.1 Optimización sin restricciones

Problema general:

$$\max_{\mathbf{x} \in \mathbb{R}^n} f(\mathbf{x})$$

(donde  $\mathbf{x} = (x_1, \dots, x_n)$ ;  $n$  es el número de variables)

- Si  $\mathbf{x}^*$  óptimo local,  $f(\mathbf{x})$  no puede aumentar dentro del conjunto factible. Entonces, debe ser cierto que satisface las siguientes condiciones de Primer Orden (CPO):

$$\frac{\partial f(\mathbf{x}^*)}{\partial x_k} = 0 \text{ para todo } k = 1, \dots, n$$

- $\frac{\partial f(\mathbf{x}^*)}{\partial x_k} = 0 \forall k$  son **condiciones necesarias** para el óptimo. Una **condición suficiente** para que un  $\mathbf{x}^*$  que satisface dichas condiciones sea realmente un óptimo (condición de Segundo Orden) es que  $f$  sea cóncava, esto es,  $H_f(\mathbf{x})$  negativa semidefinida.

## 2.2 Optimización con restricciones de igualdad

Problema general:

$$\max_{\mathbf{x} \in \mathbb{R}^n} f(\mathbf{x}) \text{ s.a. } m \text{ restricciones de la forma } g_j(\mathbf{x}) = b_j$$

(donde  $\mathbf{x} = (x_1, \dots, x_n)$ ;  $n$  es el número de variables y  $m$  de restricciones)

- Si  $\mathbf{x}^*$  óptimo local,  $f(\mathbf{x})$  no puede aumentar dentro del conjunto factible. Esto implica que  $\exists \boldsymbol{\lambda} \in \mathbb{R}^m$  tal que

$$\frac{\partial f(\mathbf{x}^*)}{\partial x_k} = \lambda_1 \frac{\partial g_1(\mathbf{x}^*)}{\partial x_k} + \dots + \lambda_m \frac{\partial g_m(\mathbf{x}^*)}{\partial x_k} \text{ para todo } k = 1, \dots, n$$

- Al escribir

$$\mathcal{L} = f(\mathbf{x}) + \sum_{j=1}^m \lambda_j [b_j - g_j(\mathbf{x})]$$

obtenemos las siguientes **condiciones necesarias** (CPO, condiciones de Primer Orden) para el óptimo:

$$\begin{aligned} \frac{\partial \mathcal{L}}{\partial x_k} &= 0 \text{ para todo } k = 1, \dots, n \\ \frac{\partial \mathcal{L}}{\partial \lambda_j} &= 0 \text{ para todo } j = 1, \dots, m \end{aligned}$$

ya que  $\frac{\partial \mathcal{L}}{\partial x_k} = \frac{\partial f(\mathbf{x}^*)}{\partial x_k} - \left( \lambda_1 \frac{\partial g_1(\mathbf{x}^*)}{\partial x_k} + \dots + \lambda_m \frac{\partial g_m(\mathbf{x}^*)}{\partial x_k} \right)$  y  $\frac{\partial \mathcal{L}}{\partial \lambda_j} = b_j - g_j(\mathbf{x})$

- Las siguientes condiciones (de Segundo Orden) son **condiciones suficientes** para que un  $\mathbf{x}^*$  que satisfice dichas CPO sea realmente un óptimo: para todo  $r \in \{m+1, \dots, n\}$ , se requiere que  $(-1)^r \overline{D}_r(\mathbf{x}^*) > 0$ , donde cada  $\overline{D}_r(\mathbf{x}^*)$  es el menor principal líder de orden  $r$  del hesiano orlado definido como:

$$\overline{H}_{\mathcal{L}}(\mathbf{x}) = \begin{bmatrix} 0 & \nabla g(\mathbf{x})^T \\ \nabla g(\mathbf{x}) & H_{\mathcal{L}}(\mathbf{x}) \end{bmatrix}$$

(con  $H_{\mathcal{L}}(\mathbf{x}^*)$  matriz de segundas derivadas de  $\mathcal{L}$  respecto de  $\mathbf{x}$ , y  $\nabla g(\mathbf{x})$  gradiente de  $g$ , o vector de primeras derivadas).

Esto es, los últimos  $n - m$  menores principales líderes de  $\overline{H}_{\mathcal{L}}(\mathbf{x}^*)$  alternan de signo, empezando con el signo de  $(-1)^{m+1}$ .

- Teorema de la envolvente:  $\frac{\partial f(\mathbf{x}^*)}{\partial b_j} = \lambda_j$ ; es decir,  $\lambda_j$  indica cuánto aumentaría el valor máximo de la función objetivo si aumentara la constante  $b_j$ . Note que en el caso de restricciones de igualdad,  $\lambda_j$  podría ser positivo, negativo o cero.

(más general: si  $a$  es cualquier parámetro del problema,  $\frac{\partial f(\mathbf{x}^*)}{\partial a} = \frac{\partial \mathcal{L}}{\partial a} \big|_{\mathbf{x}^*, \boldsymbol{\lambda}^*}$ ; esto es, basta con derivar  $\mathcal{L}$  y evaluar en el óptimo para encontrar  $\frac{\partial f(\mathbf{x}^*)}{\partial a}$ ).

## 2.3 Optimización con restricciones de desigualdad

Problema general:

$$\max_{\mathbf{x} \in \mathbb{R}^n} f(\mathbf{x}) \text{ s.a. } m \text{ restricciones de la forma } g_j(\mathbf{x}) \leq b_j$$

(donde  $\mathbf{x} = (x_1, \dots, x_n)$ ;  $n$  es el número de variables y  $m$  de restricciones)

- Si  $\mathbf{x}^*$  óptimo local,  $f(\mathbf{x})$  no puede aumentar dentro del conjunto factible. Esto implica que  $\exists \boldsymbol{\lambda} \in \mathbb{R}_+^m$  tal que

$$\frac{\partial f(\mathbf{x}^*)}{\partial x_k} = \lambda_1 \frac{\partial g_1(\mathbf{x}^*)}{\partial x_k} + \dots + \lambda_m \frac{\partial g_m(\mathbf{x}^*)}{\partial x_k} \text{ para todo } k = 1, \dots, n$$

- Al escribir

$$\mathcal{L} = f(\mathbf{x}) + \sum_{j=1}^m \lambda_j [b_j - g_j(\mathbf{x})]$$

obtenemos las siguientes **condiciones necesarias** (condiciones de KKT, condiciones de Karush-Kuhn-Tucker) para el óptimo:

$$\begin{aligned} \frac{\partial \mathcal{L}}{\partial x_k} &= 0 \text{ para todo } k = 1, \dots, n \\ \frac{\partial \mathcal{L}}{\partial \lambda_j} &\geq 0 \text{ y } \frac{\partial \mathcal{L}}{\partial \lambda_j} \lambda_j = 0 \text{ para todo } j = 1, \dots, m \end{aligned}$$

ya que  $\frac{\partial \mathcal{L}}{\partial x_k} = \frac{\partial f(\mathbf{x}^*)}{\partial x_k} - \left( \lambda_1 \frac{\partial g_1(\mathbf{x}^*)}{\partial x_k} + \dots + \lambda_m \frac{\partial g_m(\mathbf{x}^*)}{\partial x_k} \right)$  y  $\frac{\partial \mathcal{L}}{\partial \lambda_j} = b_j - g_j(\mathbf{x})$ .

- Si una restricción  $j'$  no es activa en el óptimo, entonces  $\frac{\partial \mathcal{L}}{\partial \lambda_{j'}} > 0$  (esto es,  $b_{j'} > g_{j'}(\mathbf{x}^*)$ ) pero el teorema de la envolvente indica que  $\lambda_{j'}$  debe ser cero: la restricción no afecta, por lo que aumentar  $b_{j'}$  no tiene ningún efecto sobre  $f(\mathbf{x}^*)$ .
- Si una restricción  $j''$  es activa, entonces  $\frac{\partial \mathcal{L}}{\partial \lambda_{j''}} = 0$  (esto es,  $b_{j''} = g_{j''}(\mathbf{x}^*)$ ) pero  $\lambda_{j''}$  debe ser no-negativa: si  $\lambda_{j''}$  fuera negativa, entonces al reducir  $b_{j''}$  aumentaría el valor máximo de  $f$ ; eso no es posible, porque todos los  $\mathbf{x}$  alcanzables con el nuevo  $b_{j''}$  ya eran factibles antes de reducir  $b_{j''}$  (reducir el conjunto factible no puede ser beneficioso).
- Es necesario analizar  $2^m$  casos: distintas combinaciones de  $\lambda_j$  positivos o nulos.
  - Por ejemplo, con  $m = 2$  los casos posibles son:
    - \*  $\lambda_1 = \lambda_2 = 0$  (caso en que ninguna restricción es activa, equivalente a maximización sin restricciones)
    - \*  $\lambda_1 = 0$  y  $\lambda_2 > 0$  (caso en que solo la segunda restricción es activa, equivalente a maximización con la segunda restricción de igualdad)
    - \*  $\lambda_1 > 0$  y  $\lambda_2 = 0$  (caso en que solo la primera restricción es activa, equivalente a maximización con la primera restricción de igualdad)
    - \*  $\lambda_1 > 0$  y  $\lambda_2 > 0$  (caso con dos restricciones activas, equivalente a maximización con dos restricciones de igualdad).
  - Algunos de estos casos podrían descartarse al obtener una contradicción; en los puntos críticos que se obtienen en los casos restantes se podrían verificar las condiciones de segundo orden correspondientes, o sencillamente comparar el valor de  $f$  que se obtiene al evaluarla en cada uno de los puntos críticos para elegir aquel que entrega  $f(\mathbf{x}^*)$  más alto.
- El caso de las **restricciones de no-negatividad**  $x_k \geq 0$  es un caso particular, en que la restricción se puede reescribir como  $-x_j \leq 0$  para proceder como antes. Se puede mostrar que en un caso como este las condiciones de KKT son equivalentes a:

$$\begin{aligned} \frac{\partial \mathcal{L}}{\partial x_k} &\leq 0 \text{ y } \frac{\partial \mathcal{L}}{\partial x_k} x_k \text{ para todo } k \text{ con restricción } x_k \geq 0 \\ \frac{\partial \mathcal{L}}{\partial x_k} &= 0 \text{ para todo } k \text{ sin restricción de no-negatividad} \\ \frac{\partial \mathcal{L}}{\partial \lambda_j} &\geq 0 \text{ y } \frac{\partial \mathcal{L}}{\partial \lambda_j} \lambda_j = 0 \text{ para todo } j = 1, \dots, m \end{aligned}$$

Esto es, si  $x_k$  tiene restricción de no-negatividad, entonces en el óptimo puede ocurrir que  $\frac{\partial \mathcal{L}}{\partial x_k} < 0$  si  $x_k^* = 0$ , pero cuando  $x_k^* > 0$  sigue siendo necesario que  $\frac{\partial \mathcal{L}}{\partial x_k} = 0$  como antes.

- Para obtener el valor de  $\mathbf{x}$  que **minimiza**  $f(\mathbf{x})$  dentro de un conjunto factible  $A$  basta con resolver el problema de maximización de  $-f(\mathbf{x})$  dentro del mismo conjunto  $A$ :  $\arg \min_{\mathbf{x} \in A} (f(\mathbf{x})) = \arg \max_{\mathbf{x} \in A} (-f(\mathbf{x}))$